



Análisis de documentos científicos en español

Avance de proyecto

Daniel Caro | Nicolas Ríos | Andrés Romero | Anderson Rodríguez |

William Florez

Abril 2026

Descripción de la propuesta

La propuesta de solución consiste en desarrollar un sistema para analizar documentos científicos escritos en español, con el objetivo de identificar mejor cómo están estructurados y cuáles son sus principales aportes. La idea parte de un problema claro: aunque existen muchos avances en procesamiento de lenguaje natural para textos científicos, la mayoría están enfocados en inglés, mientras que el español sigue teniendo menos recursos, modelos y datos disponibles para este tipo de tareas.

La solución se plantea como un pipeline de dos etapas. Primero, el sistema segmenta el documento y clasifica cada fragmento según su función dentro del texto académico, por ejemplo, introducción, metodología, resultados o discusión. Luego, usando esa información, el sistema intenta detectar qué fragmentos expresan contribuciones científicas reales, como métodos propuestos, resultados importantes o avances conceptuales.

Para lograrlo, se compararán distintos enfoques: modelos supervisados entrenados con textos científicos en español, modelos de lenguaje abiertos de menor tamaño y modelos comerciales usados mediante API. Además, se desarrollará un demostrador que permita ingresar un texto académico y visualizar tanto la segmentación retórica como la detección de posibles contribuciones. De esta manera, el proyecto no solo busca construir una herramienta funcional, sino también aportar evidencia sobre qué tan útiles son estos modelos para analizar producción científica en español.

Recolección y preparación de los datos

El corpus inicial proviene del repositorio CORE, una plataforma agregadora de producción académica en acceso abierto. La extracción resultó en 1.812.557 archivos .txt en español distribuidos en múltiples dominios disciplinares (ciencias exactas, ciencias sociales, humanidades, ingenierías, ciencias de la salud) y provenientes de diversas fuentes institucionales: revistas indexadas, repositorios universitarios y archivos de tesis.

El análisis inicial evidenció una variabilidad de calidad considerable: coexisten artículos limpios, tesis extensas, libros con OCR defectuoso, textos jurídicos y administrativos que no siguen la estructura IMRyD. Esta heterogeneidad motivó el

diseño de un pipeline de curaduría robusto que no dependiera exclusivamente de heurísticas basadas en encabezados.

El pipeline se dividió en dos componentes independientes que permiten iterar cada etapa sin reprocesar el corpus completo:

- **Perfilador documental:** evalúa cada archivo .txt y decide si entra al pipeline (aceptar, revisar, descartar), asignando un score de prioridad para los documentos aceptados.
- **Generador de fragmentos:** segmenta los documentos aceptados y asigna etiquetas retóricas con tres fuentes de evidencia.

Perfilador documental

El perfilador responde dos preguntas por documento: si entra al pipeline y qué tan prioritario es. Ejecuta cinco análisis: calidad textual, estructura académica, zonas (front matter / cuerpo / referencias), tipo documental y score de prioridad.

Evaluación de calidad. Parte de un puntaje base de 100 y penaliza cinco indicadores de deterioro. El más discriminante es el ratio de tildes: español académico limpio presenta entre 0,10 y 0,14 de palabras con tildes o ñ; un texto con OCR roto o en otro idioma presenta ratio cercano a cero. Se penalizan también errores tipográficos de OCR, palabras fusionadas, líneas repetidas y artefactos de fórmula.

Detección de estructura. Busca tres tipos de indicadores: encabezados estándar con expresiones regulares que cubren variantes del español académico, secciones numeradas reales y encabezados tipográficos en mayúsculas. Un documento se considera estructuralmente fuerte cuando presenta al menos tres encabezados estándar o cubre tres o más etiquetas retóricas centrales.

Decisión y priorización. El descarte directo se aplica ante menos de 300 palabras, ratio de tildes inferior a 0,02, puntaje de calidad bajo 35 o tipo documental no científico. La aceptación requiere tipo artículo o reporte, calidad ≥ 60 y estructura presente. Los documentos aceptados reciben un score de prioridad compuesto por cuatro dimensiones de 25 puntos cada una:

DIMENSIÓN	DESCRIPCIÓN
CALIDAD TEXTUAL	• Deriva del score de calidad, con bonificación por ratio de tildes alto y penalización por artefactos persistentes.

ESTRUCTURA ACADÉMICA SEGMENTABILIDAD

COBERTURA RETÓRICA

- Premia la cantidad de etiquetas detectadas y encabezados estándar.
- Evalúa la proporción de cuerpo y la cantidad de marcadores de sección (óptimo 3-15).
- Prioriza documentos que cubren múltiples etiquetas, con bonificación para clases raras (CONTR, LIM).

El score final se segmenta en tiers: prioritario (≥ 70), alto (50-70), medio (30-50) y bajo (< 30). Se aplica un bonus de rareza que empuja hacia arriba los documentos con etiquetas subrepresentadas.

Generador de fragmentos

El generador de fragmentos se encarga de preparar los textos para el dataset. Primero limpia el documento, eliminando partes como referencias, encabezados repetidos y contenido inicial que no aporta al análisis. Luego divide el texto en secciones y construye chunks entre **250 y 1000 palabras**, siguiendo los límites definidos para el proyecto.

Después, cada chunk recibe una etiqueta retórica mediante reglas heurísticas. Para esto se tienen en cuenta tres señales principales: el encabezado de la sección, palabras o patrones asociados a cada etiqueta y la posición del fragmento dentro del documento. La posición no se usa sola, sino como apoyo cuando ya existe alguna señal textual.

Las etiquetas CONTR y LIM tienen un tratamiento especial porque aparecen con menor frecuencia y pueden generar falsos positivos. Por eso, solo se asignan cuando el fragmento tiene varias señales claras de contribución o limitación, y no solo porque aparezca una palabra como “aporte” o “limitación”.

Finalmente, por cada chunk se generan dos versiones: una con el texto original y sus pistas, y otra donde se eliminan encabezados o señales muy evidentes. Esto se hace para evitar que los modelos aprendan atajos simples y obligarlos a clasificar usando mejor el contenido del fragmento.

Proceso de construcción

El perfilador pasó por cinco iteraciones que reflejan la complejidad del problema de curaduría. La versión 1 solo buscaba encabezados estándar. La versión 3 introdujo el

ratio de tildes como indicador primario de calidad. La versión 5, actual, separó explícitamente la decisión de entrada del ranking documental y añadió el bonus de rareza.

El chunker se aplicó sobre los tres tiers del perfilador en rondas sucesivas, siguiendo una estrategia de procesamiento por prioridad que permitió medir cobertura y ajustar parámetros antes de procesar el corpus completo. La integración final aplicó filtros diferenciados por tier, preservando mayor retención del tier prioritario y criterios más estrictos para los tiers medio y bajo, respondiendo a la calidad observada en cada caso.

Descripción del proceso de construcción de los modelos o solución

La solución se construirá como un pipeline de dos etapas. Primero, el sistema recibirá un documento científico en español, lo dividirá en fragmentos y clasificará cada uno según su función retórica, como introducción, metodología, resultados, discusión, entre otras.

Para esta primera tarea se entrenarán modelos supervisados usando encoders preentrenados en español científico, principalmente SciBETO-large. También se tendrá una línea base generalista en español para poder comparar si un modelo especializado en textos científicos realmente mejora los resultados.

Además de los modelos entrenados, también se probarán modelos de lenguaje de menor tamaño como Qwen2.5:3b y Llama3.2:3b, junto con modelos comerciales usados mediante API, como GPT-5 mini y Gemini 2.5 Flash. Estos modelos se evaluarán usando estrategias de prompting como zero-shot y few-shot, para comparar su desempeño frente a los modelos entrenados directamente.

En la segunda etapa, el sistema usará los fragmentos del documento para detectar si contienen o no una contribución científica. Esta parte se trabajará como una clasificación binaria: el fragmento puede ser marcado como contribución o no contribución. Primero se entrenará un modelo usando solo el texto del fragmento. Después se probará una versión enriquecida, donde además del texto se usará la etiqueta retórica obtenida en la primera etapa y la posición del fragmento dentro del documento.

Finalmente, se desarrollará un demostrador donde el usuario podrá ingresar un texto académico y visualizar la segmentación, las etiquetas asignadas y las posibles contribuciones detectadas.

Resultados obtenidos

Hasta el momento se procesó un subconjunto del corpus CORE. En esta primera revisión, muchos documentos fueron descartados porque no tenían una estructura académica clara o no correspondían a textos científicos. Dentro de los documentos aceptados, el perfilador identificó 36.911 con cobertura de INTRO (78,1%), 24.059 con CONC (50,9%), 13.037 con RES (27,6%), 11.737 con METH (24,8%), 5.646 con DISC (11,9%), 3.182 con BACK (6,7%), 361 con LIM (0,8%) y 115 con CONTR (0,2%). Esta distribución confirma la escasez estructural de CONTR y LIM en el corpus español académico.

Después, el generador de fragmentos procesó **42.772 documentos** y produjo **146.964 chunks**. También se eliminaron **63 duplicados** y hubo **13.380 documentos fallidos**, principalmente por problemas durante el preprocesamiento del texto.

ETIQUETA	CHUNKS	META (2000)	CUMPLIMIENTO
INTRO	40.923	✓	Superada ampliamente
METH	14.562	✓	Superada
CONC	13.337	✓	Superada
RES	12.751	✓	Superada
BACK	5.459	✓	Superada
DISC	5.003	✓	Superada
LIM	486	24%	Bajo meta
CONTR	194	10%	Bajo meta

De las ocho etiquetas trabajadas, seis superaron la meta de **2.000 ejemplos por clase**. Las únicas que quedaron por debajo fueron LIM y CONTR, lo cual era esperable porque son etiquetas menos frecuentes dentro de los documentos científicos. Aun así, se obtuvo suficiente material para hacer la revisión manual.

De los **92.715 chunks etiquetados**, el **73,8%** tuvo confianza alta, el **9,1%** confianza media y el **17,1%** confianza baja. También quedaron **54.249 chunks sin asignación**, principalmente porque no tenían un encabezado claro o señales suficientes para clasificarlos automáticamente. Estos fragmentos se conservaron para una posible revisión o reprocesamiento posterior.

En cuanto a la longitud, los chunks cumplen con los criterios definidos. Todos tienen mínimo **250 palabras** y máximo **1000**, sin superar el límite establecido. Además, las medianas por etiqueta están entre **443 y 552 palabras**, por lo que el tamaño de los fragmentos se mantiene bastante estable entre clases.

Para la validación manual, el equipo anotó **307 chunks sin etiqueta previa**, usando dos anotadores por fragmento para calcular el acuerdo entre evaluadores. El resultado de **Cohen's Kappa fue 0.3785**, lo que indica un acuerdo bajo a moderado. Esto muestra que todavía hay diferencias en la forma en que se interpretan algunas etiquetas, por lo que será necesario revisar la guía y ajustar algunos criterios antes de entrenar los modelos finales.

Además, se revisaron **1.230 chunks** que ya tenían una etiqueta propuesta por el pipeline. En estos casos, los anotadores confirmaron la etiqueta o la corrigieron cuando era necesario. Estas muestras revisadas se reservarán para la evaluación de los modelos, mientras que el resto del dataset se usará para entrenamiento y validación interna.

Para la segunda tarea, queda pendiente construir el dataset de contribuciones científicas. Este deberá incluir fragmentos positivos, donde sí se exprese una contribución, y fragmentos negativos, donde no haya una contribución explícita. La meta propuesta es tener al menos **1.000 ejemplos positivos y 1.000 negativos**, los cuales también deberán pasar por revisión manual.

Análisis, retos y próximos pasos

Una dificultad importante fue la calidad variable del corpus. Algunos documentos estaban bien organizados, pero otros tenían problemas de OCR, estructuras poco claras o mucho contenido inicial que no aportaba al análisis. Para manejar esto, se usó el ratio de tildes como una señal de calidad del texto, sin descartar automáticamente documentos que todavía podían servir.

También se encontró que las etiquetas CONTR y LIM aparecen muy poco. En muchos textos académicos en español, las contribuciones y limitaciones no están en secciones separadas, sino mezcladas dentro de la introducción, la conclusión u otros párrafos. Por eso, su baja presencia parece ser una característica del corpus y no necesariamente un error del pipeline.

Otro problema fue que palabras como “aporte”, “contribución” o “limitación” no siempre se usan en sentido científico. A veces aparecen en contextos económicos,

jurídicos o generales, lo que puede generar falsos positivos. Para reducir esto, se aplicaron reglas más estrictas al momento de asignar la etiqueta dominante.

Lecciones aprendidas

La modularización del pipeline en scripts independientes permitió iterar cada componente sin reprocesar etapas anteriores y facilitó el trabajo paralelo del equipo. La estrategia de procesamiento por tiers con filtros diferenciados fue efectiva frente a un enfoque de filtros uniformes, preservando la calidad del aporte del tier prioritario sin descartar los tiers inferiores.

Próximos pasos

1. Calcular la tasa de error del pipeline automático por etiqueta a partir del conjunto de corroboración, para caracterizar la precisión del etiquetado heurístico.
2. Realizar la partición train/val/test del dataset respetando el criterio de no solapamiento por documento, con estratificación por etiqueta y semilla fija.
3. Generar la versión desacoplada particionada según la actividad A3 del enunciado.
4. Documentar formalmente el dataset con metadatos completos para transferencia a los compañeros responsables del modelado.

Ajustes para iteraciones posteriores

Para la segunda iteración se contempla el desarrollo de un detector de pasajes especializado para CONTR y LIM basado en identificación de oraciones-claim individuales y expansión de ventana de contexto, que permitiría cerrar la brecha de estas clases críticas sin depender exclusivamente de encabezados explícitos. Se evaluará también la incorporación de búsqueda semántica con embeddings en español para complementar la detección léxica.

Bibliografía

- D'Souza, J., Auer, S., & Pedersen, T. (2021). SemEval-2021 Task 11: NLPContributionGraph - Structuring scholarly NLP contributions for a research knowledge graph. En Proceedings of the 15th International Workshop on Semantic Evaluation (SemEval-2021) (pp. 364–376). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.semeval-1.44>

- Kataria, H., & Gupta, A. (2023). NLP-Titan at SemEval-2023 Task 6: Identification of rhetorical roles using sequential sentence classification. En Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023) (pp. 1365–1370). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.semeval-1.189>
- Liakata, M., Teufel, S., Siddharthan, A., & Batchelor, C. (2010). Corpora for the conceptualisation and zoning of scientific papers. En Proceedings of the Seventh International Conference on Language Resources and Evaluation (LREC'10). European Language Resources Association.
- Teufel, S., & Moens, M. (1999). Discourse-level argumentation in scientific articles: Human and automatic annotation. En Towards Standards and Tools for Discourse Tagging.