

# Análisis de documentos científicos en español

Grupo de investigación FLAG – TICsW. Departamento de Ingeniería de Sistemas y Computación. Universidad de los Andes.

Grupo del proyecto: Andres Felipe Romero Torres, Anderson Eduardo Rodríguez, Daniel Felipe Caro Torres, Nicolas Steven Rios Perez, William James Florez Maestre

## Contexto, problema y Justificación. Impacto esperado.

El crecimiento sostenido de la producción científica ha incrementado la necesidad de métodos automáticos para el análisis y la organización de textos académicos. Las técnicas de PLN han permitido avances relevantes en tareas como la clasificación de documentos, la extracción de información y la generación de resúmenes científicos, principalmente para textos en inglés. Estos desarrollos apoyan procesos como la revisión de literatura, la evaluación de la producción académica y la gestión del conocimiento. Sin embargo, la mayoría de los modelos, recursos y conjuntos de datos existentes han sido diseñados para el inglés, lo que limita su aplicación en otros idiomas.

El español es una de las lenguas más utilizadas en la comunicación científica, en particular en tesis, informes técnicos y revistas regionales. A pesar de ello, los textos científicos en español han recibido una atención limitada en la investigación en PLN. La escritura académica en español presenta desafíos específicos, como una mayor variabilidad estructural entre tipos de documentos, convenciones retóricas dependientes del dominio y una escasa disponibilidad de corpus anotados. Estas características dificultan la transferencia directa de modelos entrenados en inglés y justifican el desarrollo de enfoques específicos para este idioma.

Este proyecto aborda el análisis automático de documentos científicos en español a través de dos tareas complementarias. La primera es la segmentación y clasificación retórica, cuyo objetivo es identificar la función discursiva de secciones o fragmentos de texto dentro de un documento, tales como introducción, metodología, resultados o discusión. La identificación precisa de la estructura retórica constituye una base necesaria para la comprensión del contenido científico y para el desarrollo de tareas de análisis a nivel de documento.

La segunda tarea es la extracción automática de contribuciones científicas, entendidas como unidades textuales que describen los aportes originales de un trabajo, incluyendo métodos propuestos, resultados relevantes o avances conceptuales. La identificación de contribuciones es fundamental para la revisión de literatura, la evaluación académica y la organización del conocimiento científico. En los textos académicos en español, las

contribuciones suelen expresarse de forma indirecta y distribuida a lo largo del documento, lo que incrementa la complejidad de esta tarea.

Al combinar la segmentación retórica con la extracción de contribuciones, este proyecto analiza el impacto de la información discursiva en la identificación de los aportes científicos en documentos académicos escritos en español.

## Objetivos

**Objetivo General:** El objetivo es aportar modelos, datos y evidencia empírica que contribuyan al estudio del PLN científico más allá del inglés, con un enfoque específico en el español como lengua con recursos limitados en este dominio.

### Objetivos Específicos:

- Caracterizar un corpus a gran escala de documentos científicos en español, extraído de CORE.
- Definir un esquema de anotación retórica y de contribuciones científicas adecuado para textos académicos en español, junto con una guía de anotación que permita evaluar la consistencia y el acuerdo entre anotadores.
- Desarrollar modelos de segmentación y clasificación retórica entrenados específicamente para textos científicos en español, utilizando arquitecturas de tamaño reducido o medio, y evaluar cuantitativamente su desempeño.
- Desarrollar modelos automáticos para la extracción de contribuciones científicas, considerando enfoques de clasificación de oraciones y detección de fragmentos textuales, y analizar su dependencia de la estructura retórica del documento.
- Evaluar el uso de modelos de lenguaje de gran escala consumidos vía API como aproximación alternativa para ambas tareas, analizando su desempeño bajo diferentes estrategias de prompting y su capacidad de generalización.
- Comparar el desempeño, costo computacional y estabilidad de resultados entre los modelos de lenguaje de gran escala y los clasificadores entrenados, considerando métricas cuantitativas.

## Estado del arte

La literatura sobre análisis discursivo de textos científicos muestra que un artículo académico no se organiza únicamente por secciones visibles como introducción, metodología o conclusiones, sino también por funciones argumentativas que reflejan el papel que cumple cada fragmento dentro del razonamiento científico. En esta línea, el trabajo de Teufel y Moens (1999) es un antecedente fundacional, ya que propone modelar la estructura argumentativa de los artículos científicos mediante anotación humana y

automática, sentando una base conceptual para tareas de clasificación retórica más finas que la simple detección de encabezados.

Posteriormente, esta línea evolucionó hacia la construcción de corpus anotados de artículos científicos completos, lo que permitió pasar de una formulación teórica a escenarios experimentales más sólidos. Liakata et al. (2010) presentan los esquemas CoreSC y AZ-II, aplicados a papers completos de química, y muestran que es posible anotar de forma consistente tanto la dimensión retórica como la dimensión conceptual del contenido científico.

En cuanto a las técnicas utilizadas, el estado del arte reciente se ha desplazado hacia enfoques de clasificación secuencial, donde la etiqueta de una oración depende también del contexto de las oraciones vecinas. En este punto se ubica el aporte de Kataria y Gupta (2023), quienes, en el marco de SemEval-2023 Task 6, utilizan una red de etiquetado secuencial jerárquico con representaciones basadas en BERT para identificar roles retóricos en documentos legales. Aunque su dominio no es el científico, su contribución sigue siendo relevante para este proyecto porque confirma que el modelado secuencial mejora la identificación de roles discursivos y que la organización interna del documento aporta información útil para la clasificación (Kataria & Gupta, 2023).

Finalmente, para la segunda tarea, el antecedente más cercano es SemEval-2021 Task 11: NLPContributionGraph, que formaliza la identificación de contribution sentences como un problema específico dentro de artículos científicos. Este trabajo es importante porque muestra que detectar contribuciones científicas es una tarea distinta y más difícil que la simple clasificación retórica, y porque evidencia que la extracción de aportes puede servir como base para estructurar conocimiento científico en grafos o repositorios semánticos. En conjunto, estos antecedentes permiten identificar una brecha clara: aunque existen avances sólidos en clasificación retórica y en extracción de contribuciones, la mayor parte de la evidencia previa se concentra en inglés o en dominios específicos, lo que da sentido al desarrollo de un enfoque orientado a documentos científicos en español y a la relación entre ambas tareas (D'Souza et al., 2021).

## Metodología y enfoque propuesto

La solución propuesta se concibe como un pipeline de dos etapas. En la primera se realizará la clasificación retórica de fragmentos textuales de documentos científicos en español, con el fin de identificar su función discursiva dentro de la estructura del artículo. En la segunda se abordará la detección automática de contribuciones científicas explícitas, utilizando tanto el contenido del fragmento como señales contextuales derivadas de la primera etapa, particularmente la etiqueta retórica y la posición relativa dentro del documento

Para la tarea 1: Se desarrollarán clasificadores supervisados basados en encoders preentrenados en español científico, con especial énfasis en SciBETO-large,

complementados con una línea base generalista en español. La tarea se formulará principalmente como clasificación monolabel de etiqueta dominante, con el fin de facilitar la anotación, el entrenamiento y la comparación entre enfoques; sin embargo, en el demostrador se visualizará también la segunda etiqueta más probable cuando el modelo lo permita, para reflejar la posible superposición entre funciones discursivas. En paralelo, se evaluarán modelos open-weight de entre 1B y 8B parámetros (Qwen2.5:3b + Llama3.2:3b) y modelos comerciales consumidos vía API (GPT-5 mini + Gemini 2.5 Flash), todos bajo estrategias de prompting comparables incluyendo los enfoques Zero-shot y Few-shot .

Para la tarea 2: se entrenarán clasificadores binarios orientados a distinguir entre fragmentos que contienen contribuciones científicas explícitas y fragmentos que no las contienen. Se comparará un baseline basado únicamente en el texto del fragmento con variantes enriquecidas que incorporen la etiqueta retórica predicha por la Tarea 1 y la posición relativa del fragmento dentro del documento. De manera análoga a la Tarea 1, se evaluarán encoders supervisados, modelos open-weight (Qwen2.5:3b + Llama3.2:3b) en modo de inferencia y modelos comerciales vía API (GPT-5 mini + Gemini 2.5 Flash) con prompting equivalente, con el fin de asegurar comparabilidad metodológica.

Estas dos tareas estarán desplegadas en un tablero que permitirá al usuario seleccionar cual acercamiento usar para la inferencia si los encoders preentrenados, los modelos de lenguaje de menor tamaño o los modelos comerciales de gran escala, recibirá como entrada el texto completo o parcial del artículo académico, el sistema ejecutará la tarea 1 segmentando el texto y asignando las etiquetas retóricas y usando elementos visuales para para acentuar esta segmentación, sobre esta segmentación ejecutará la tarea 2 evaluando cada sección y mostrando la etiqueta binaria y dependiendo el modelo la puntuación de confianza.

**Herramientas:** Para el proyecto se planean usar python, pytorch, Qwen2.5:3b, Llama3.2:3b, OpenAI API, Gemini API, StreamLit, FastAPI, MLFlow, AWS.

## Exploración y descripción de los datos

**Características de los datos:** La preparación de datos partirá del corpus inicial de 1.812.557 documentos científicos en español extraídos de CORE, el cual incluye artículos académicos, tesis y reportes técnicos de múltiples dominios. Dado que este corpus proviene de una fuente abierta y presenta variabilidad en calidad y estructura, primero se realizará una etapa de curaduría para conservar únicamente documentos con organización académica reconocible. Posteriormente, se aplicará una fase de normalización textual orientada a eliminar referencias bibliográficas, figuras, tablas y otros elementos no textuales que puedan afectar la segmentación y el entrenamiento de los modelos. Esta etapa se apoyará en la versión preprocesada entregada por el grupo FLAG, reconociendo

que el texto ya fue limpiado parcialmente, pero que aún puede contener ruido, errores de extracción y casos que requieran revisión puntual sobre el documento original.

**Preparación de datos:** Para el dataset de la tarea 1: Los documentos se segmentarán en unidades textuales continuas, correspondientes a secciones o bloques coherentes, y se aplicarán heurísticas basadas en encabezados, posición relativa y patrones léxicos para asignar etiquetas retóricas preliminares. A partir de estos candidatos se construirá un dataset balanceado con al menos 2000 ejemplos por etiqueta, cada uno con una longitud máxima de 1000 palabras, garantizando que las particiones de entrenamiento, validación y evaluación no compartan fragmentos provenientes del mismo documento.

Una vez construido el dataset preliminar, se seleccionarán al menos el 10% de los ejemplos por cada etiqueta retórica para validación manual por parte del grupo. Cada ejemplo será revisado por más de un anotador con el fin de medir el grado de consistencia del proceso. El acuerdo interanotador se cuantifica mediante métricas estándar Fleiss' Kappa. Las muestras validadas por el grupo se reservarán exclusivamente para la evaluación final de los modelos.

Después se eliminarán o neutralizarán los patrones utilizados en la construcción del dataset para que el modelo no aprenda directamente de estos, esto conlleva la supresión de expresiones usadas para encontrar las secciones (“Metodología”, “Introducción”, “Estado del Arte”, “Trabajos relacionados”, etc).

Para el dataset de la tarea 2: Se construirá un dataset compuesto por al menos 1000 fragmentos que expresen explícitamente contribuciones científicas, donde cada fragmento estará asociado de forma explícita a su artículo de origen y a su ubicación dentro del documento. No se impondrá una longitud máxima para los fragmentos positivos, con el fin de preservar el contexto necesario para comprender adecuadamente el aporte científico. De manera complementaria, se identificarán al menos 1000 fragmentos negativos, con longitudes comprendidas entre 250 y 500 palabras, en los que no se identifique ninguna formulación explícita de contribución científica.

Luego a partir de este dataset preliminar el 10% de los fragmentos positivos y negativos será validado manualmente por el grupo. En el caso de los fragmentos positivos, los anotadores verificarán que el texto seleccionado represente efectivamente una contribución científica y no una reformulación de antecedentes, metodología estándar o resultados sin novedad. Para los fragmentos negativos, se confirmará la ausencia de formulaciones explícitas de contribución. Para las anotaciones manuales se dará el mismo tratamiento que en el de la tarea 1.

## Consideraciones Éticas

**Impacto social y ético.** Consideramos que esta propuesta impacta favorablemente en el aspecto social ya que busca extender y aportar al área de PLN en el idioma español, lo que

permite tener datos y modelos que tengan en cuenta las regiones no angloparlantes dando mayor representación a estas ya que la mayoría de las aportaciones, grandes modelos y datasets se han hecho en inglés, además los datos y el enfoque con el que se trabaja no se relaciona directamente con ninguna persona o grupo social al solo segmentar el texto con las etiquetas correspondientes a las secciones de un artículo científico.

**Sesgos y su mitigación.** Para la identificación y mitigación de sesgos, se abordarán de manera integral las dimensiones de los datos, los modelos y la validación humana. A nivel de datos, el corpus extraído de CORE presenta un riesgo inherente de sobrerrepresentar ciertas áreas del conocimiento (como ciencias exactas frente a ciencias sociales), instituciones o variantes geográficas, lo que podría sesgar al modelo hacia vocabularios y convenciones retóricas particulares. Para mitigar esto y garantizar la equidad en los resultados, se aplicará un muestreo estratificado predictivo durante la construcción de los conjuntos de entrenamiento y evaluación, buscando una distribución lo más balanceada posible según los metadatos de dominio de conocimiento y origen. Finalmente, para mitigar los sesgos cognitivos e interpretativos introducidos durante la validación manual de las expresiones, los anotadores se regirán por una guía de anotación estricta y transparente, utilizando la medición constante del acuerdo interanotador para mantener la máxima objetividad posible.

**Transparencia y explicabilidad.** La solución incorporará transparencia y explicabilidad en tres niveles: datos, modelo e interfaz. Para los datos se documentará el origen del corpus, las heurísticas de selección, el proceso de anotación y la validación humana del conjunto de evaluación para garantizar trazabilidad y reproducibilidad. Para el modelo se explorarán técnicas de explicabilidad sobre una muestra representativa del conjunto de evaluación. Para los modelos open-weight se analizarán atribuciones a nivel de logits y sensibilidad ante perturbaciones del input. Para los modelos vía API, donde no hay acceso a representaciones internas, se empleará self-explanation prompting y análisis de consistencia ante variaciones textuales. En clasificación multi-etiqueta, las atribuciones se calcularán por etiqueta predicha. Y para la interfaz el demostrador mostrará la segmentación retórica, la clasificación de cada fragmento y, cuando el modelo lo permita, una puntuación de confianza. Para los modelos generativos, la evidencia provendrá de las justificaciones producidas por el propio modelo.

**Privacidad y seguridad.** El proyecto no trabaja con datos sensibles en sentido estricto, ya que se basa en documentos científicos en español; sin embargo, algunos textos pueden contener metadata identificable, como nombres de autores, afiliaciones o correos institucionales. Por ello, se conservará únicamente la información necesaria para la trazabilidad y validación del experimento, como el identificador del documento y la ubicación del fragmento, evitando exponer metadata irrelevante en los entregables o en el demostrador. Los archivos fuente, los datasets derivados y los resultados experimentales

se manejarán en entornos de acceso restringido al equipo y, en caso de utilizar modelos vía API, se enviará solo el texto estrictamente necesario para la inferencia.

## Evaluación y Métricas

Para la tarea 1 se compararán los enfoques utilizando Macro F1, Micro F1 y precisión por etiqueta, además se hará un estudio detallado de matrices de confusión y de los errores más frecuentes, por último, se realizará un análisis de costo y eficiencia de cada enfoque, además de un análisis de rendimiento que permita determinar cómo escalar el sistema en un futuro.

Para la tarea 2 el análisis de los resultados se hará con las métricas de precisión, recall y F1 al tratarse de una clasificación binaria, complementado con un análisis cualitativo de errores centrado en identificar patrones recurrentes de falsos positivos y falsos negativos, la influencia de la longitud del fragmento y el impacto de la información retórica.

## Cronograma

### Sem 1–2 (23 mar – 05 abr) · Pipeline de datos

- Selección heurística por encabezados de sección
- Construcción de candidatos Tarea 1 ( $\geq 2.000$  ejemplos por etiqueta)
- Construcción de candidatos Tarea 2 ( $\geq 1.000$  fragmentos positivos y negativos)
- Estadísticas del corpus: distribución de etiquetas, longitud de fragmentos
- Análisis de calidad del texto (ruido OCR, encoding)
- Normalización unicode, eliminación de referencias bibliográficas y fórmulas
- Enmascaramiento de encabezados de sección: dataset v1  $\rightarrow$  v2
- Anotación manual del  $\geq 10\%$  de ejemplos por etiqueta
- Cálculo del acuerdo interanotador (Fleiss' Kappa)
- Construcción del split train/val/test sin solapamiento a nivel de documento

### Sem 3 (06 abr – 12 abr) · Desarrollo de modelo propuesto Tarea 1

- Fine-tuning de SciBETO-large para Tarea 1
- Evaluación sobre conjunto validado por humanos: Macro-F1, Micro-F1 por clase
- Prompting zero-shot y few-shot con Qwen2.5:3b + Llama3.2:3b
- Prompting con GPT-5 mini + Gemini 2.5 Flash

### Sem 4 (13 abr – 19 abr) · Desarrollo de modelo propuesto tarea 2

- Entrenar encoder binario para contribución/no contribución
- Entrenamiento con versión enriquecida por la tarea 1
- Prompting zero-shot y few-shot con Qwen2.5:3b + Llama3.2:3b
- Prompting con GPT-5 mini + Gemini 2.5 Flash
- Medir precisión, recall y F1 sobre evaluación validada por humanos

### **Sem 5 y 6 (20 abr – 03 may) · Análisis comparativo, iteración y cierre técnico**

- Crear tabla comparativa global de ambas tareas
- Hacer análisis cuantitativo y cualitativo de errores
- Selección de los modelos que irán a la demo
- Especificación funcional del demostrador
- Comparar encoder vs open-weight vs comercial
- Analizar impacto de longitud, disciplina y etiqueta retórica
- Seleccionar una versión estable por familia para desplegar

### **Sem 7 (04 may – 10 may) · Despliegue y redacción final**

- Desarrollo del backend funcional del demostrador en FastAPI
- Interfaz con visualización de segmentación y contribuciones en Gradio
- Borrador completo del documento
- Figuras: arquitectura, flujo y tablas principales

### **Sem 8 (11 may – 17 may) · Pulido final, pruebas y entrega**

- Documento final revisado
- Demo probada con varios artículos
- Anexos técnicos y referencias
- Pruebas end-to-end con papers reales en español

## **Bibliografía**

D'Souza, J., Auer, S., & Pedersen, T. (2021). *SemEval-2021 Task 11: NLPContributionGraph - Structuring scholarly NLP contributions for a research knowledge graph*. En *Proceedings of the 15th International Workshop on Semantic Evaluation (SemEval-2021)* (pp. 364–376). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.semeval-1.44>

Kataria, H., & Gupta, A. (2023). *NLP-Titan at SemEval-2023 Task 6: Identification of rhetorical roles using sequential sentence classification*. En *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)* (pp. 1365–1370). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.semeval-1.189>

Liakata, M., Teufel, S., Siddharthan, A., & Batchelor, C. (2010). *Corpora for the conceptualisation and zoning of scientific papers*. En *Proceedings of the Seventh International Conference on Language Resources and Evaluation (LREC'10)*. European Language Resources Association.

Teufel, S., & Moens, M. (1999). *Discourse-level argumentation in scientific articles: Human and automatic annotation*. En *Towards Standards and Tools for Discourse Tagging*.