

REPORTE DE DESPLIEGUE

Pry-ScienceDocsSpanish

Analisis Retorico (T1) + Deteccion de Contribuciones (T2)

Articulos cientificos en espanol

FastAPI + AWS ECS Fargate + Amazon ECR + CloudWatch

Dos familias de modelos: Encoder (SciBETO)

Universidad de los Andes

Rol de Ingeniero de Implementacion

1. Resumen Ejecutivo

Este documento describe el despliegue de la API REST que sirve los modelos del proyecto Pry-ScienceDocsSpanish en Amazon Web Services. El sistema es un demostrador interactivo que recibe texto científico en español, lo segmenta en párrafos y aplica dos tareas en cascada sobre cada uno: clasificación retórica (Tarea 1, ocho categorías IMRaD extendidas) y detección binaria de contribución científica (Tarea 2). La interfaz permite seleccionar dinámicamente entre dos familias de modelos: un encoder fine-tuneado en español científico (SciBETO-large) y un modelo comercial vía API (Google Gemini 2.5 Flash).

El despliegue se ejecuto en la cuenta AWS Academy (account 207443664335, region us-east-1) usando ECS Fargate como plataforma serverless de contenedores. La imagen Docker, versionada como v2.0.0 en Amazon ECR, incorpora los dos modelos encoder descargados desde HuggingFace Hub y la integración con la API de Gemini. El secreto GEMINI_API_KEY se gestiona vía AWS Systems Manager Parameter Store.

URL publica del servicio

Endpoint	URL
Swagger UI (recomendado)	http://100.27.211.193:8000/docs
Health check	http://100.27.211.193:8000/health
Lista de modelos	http://100.27.211.193:8000/modelos
Tarea 1 (POST)	http://100.27.211.193:8000/clasificar
Tarea 2 (POST)	http://100.27.211.193:8000/contribucion
Pipeline T1+T2 (POST)	http://100.27.211.193:8000/analizar

Los tres endpoints POST aceptan el campo "modelo" con los valores "scibeto" o "gemini", permitiendo al usuario alternar entre familias sin cambiar de URL.


Resultado de validacion

Prueba	Modelo	Resultado
Tarea 1: "Se reclutaron 100 pacientes..."	scibeto	METH (96.81 %)
Tarea 1: mismo texto	gemini	METH (95 %)
Tarea 2: "Este trabajo propone un nuevo metodo"	scibeto	contribucion (99.98 %)
Tarea 2: mismo texto	gemini	contribucion (95 %)
Pipeline /analizar con 3 parrafos	scibeto	INTRO + CONTR + LIM identificados
Pipeline /analizar con 3 parrafos	gemini	INTRO + CONTR + LIM identificados

2. Arquitectura del Despliegue


El sistema sigue una arquitectura de servicio API contenerizado, ampliamente usada en despliegues cloud-native. La elección se justifica por tres razones: los modelos encoder son pesados (~1.4 GB cada uno) y deben cargarse una sola vez por contenedor; los usuarios consumen la API bajo demanda con latencia interactiva; y ECS Fargate elimina la necesidad de gestionar instancias EC2, ofreciendo healthchecks, rollouts y auto-relanzamiento automáticos.

Diagrama logico



Componentes y responsabilidades

Componente AWS	Responsabilidad
ECR Repository	Almacena la imagen Docker versionada de la API
ECS Cluster + Service	Ejecuta y mantiene viva la task; auto-relanzamiento ante fallos
ECS Task Definition	Declara recursos (2 vCPU, 6 GB), networking, healthcheck, secret
Security Group	Controla puertos expuestos al exterior (TCP 8000 abierto)
CloudWatch Logs	Captura logs de Uvicorn para auditoria y debugging
Parameter Store	Almacena GEMINI_API_KEY como SecureString
IAM LabRole	Permisos de la task para leer ECR, escribir logs, leer secrets



3. Configuración AWS y carga del secreto

Las credenciales temporales del Learner Lab se cargan al cliente AWS CLI. El secreto GEMINI_API_KEY se almacena cifrado en Parameter Store y se inyecta al runtime de la task sin quedar nunca en disco ni en la imagen.

```
$ aws sts get-caller-identity
{
  "Account": "207443664335",
  "Arn": "arn:aws:sts::207443664335:assumed-role/voclabs/..."
}

$ aws ssm put-parameter \
  --name "/pry-sciencedocs/GEMINI_API_KEY" \
  --value "<clave>" --type SecureString \
  --region us-east-1
```

3.2. Construcción y publicación de la imagen

El build se ejecuta en una EC2 bastion para aprovechar el ancho de banda de AWS al descargar los modelos desde HuggingFace Hub (~3 GB combinados) y al hacer push a ECR (red interna). La automatización via AWS Systems Manager Run Command evita SSH manual y deja trazabilidad completa en CloudWatch.


```
$ docker build -t pry-sciencedocs-api:v2.0.0 .

$ aws ecr get-login-password --region us-east-1 \
  | docker login --username AWS --password-stdin $ECR_URI

$ docker tag pry-sciencedocs-api:v2.0.0 $ECR_URI:v2.0.0
$ docker tag pry-sciencedocs-api:v2.0.0 $ECR_URI:v2.0.0-20260517

$ docker push $ECR_URI:v2.0.0
$ docker push $ECR_URI:v2.0.0-20260517

# Digest resultante:
# sha256:f49ba604571825620d3d4072708a0c0d854e6eae7c17a6d05ce491477123df06
```



3.3. Task definition con secret

La task definition `pry-sciencedocs-task:2` declara los recursos (2 vCPU, 6 GB RAM), el container basado en la imagen `v2.0.0`, el puerto `8000`, el healthcheck que valida `/health`, y la inyeccion del secret de Gemini desde Parameter Store via la propiedad `"secrets"`.

Fragmento relevante de la task definition (JSON):

```
{
  "family": "pry-sciencedocs-task",
  "cpu": "2048", "memory": "6144",
  "requiresCompatibilities": ["FARGATE"],
  "containerDefinitions": [{
    "name": "pry-api",
    "image": "207443664335.dkr.ecr.us-east-1.amazonaws.com/pry-sciencedocs-api:v2.0.0",
    "portMappings": [{ "containerPort": 8000, "protocol": "tcp" }],
    "secrets": [{
      "name": "GEMINI_API_KEY",
      "valueFrom": "arn:aws:ssm:us-east-1:207443664335:parameter/pry-sciencedocs/GEMINI_API_KEY"
    }],
    "healthCheck": {
      "command": ["CMD-SHELL", "curl -fsS http://localhost:8000/health || exit 1"],
      "interval": 30, "timeout": 5, "retries": 3, "startPeriod": 180
    }
  ]
}
```

3.4. Service ECS con rolling deployment

El service pry-sciencedocs-svc se actualiza con la nueva task definition usando `--force-new-deployment`. ECS gestiona el rolling: levanta una task nueva, espera healthcheck y termina la anterior, sin downtime perceptible para el usuario.

```
$ aws ecs update-service \
  --cluster pry-sciencedocs-cluster \
  --service pry-sciencedocs-svc \
  --task-definition pry-sciencedocs-task:2 \
  --force-new-deployment

# Transición observada:
# PROVISIONING (~30s) -> PENDING (~60s, pull ECR)
#                       -> RUNNING (~60s, carga modelos)
#                       -> HEALTHY (~30s, primer /health OK)
```

The screenshot displays the AWS Management Console for the 'pry-sciencedocs-svc' service. The interface includes a left-hand navigation pane with options like 'Express Mode', 'Clusters', 'Namespaces', and 'Task definitions'. The main content area is titled 'pry-sciencedocs-svc' and shows a 'Service overview' section with a status of 'Active' and a progress bar for tasks (1 Desired, 0 Pending, 1 Running). Below this, the 'Configuration and networking' tab is selected, showing details for 'Service configuration' and 'Network configuration'. The 'Service configuration' section includes fields for 'Service ARN', 'Task definition: revision', 'Launch type', 'Platform version', 'Availability Zone rebalancing', 'Platform family', 'CloudFormation stack', 'Scheduling strategy', 'Amazon ECS managed tags', and 'ECS Exec'. The 'Network configuration' section includes 'VPC', 'Subnets', 'Security groups', 'Auto-assign public IP', 'Service role', and 'Health check grace period'.

Service overview	
Status: Active	Tasks (1 Desired): 0 Pending 1 Running
Task definition: revision: pry-sciencedocs-task:2	Deployment status: Success

Service configuration	
Service ARN: arn:aws:ecs:us-east-1:207443664335:service/pry-sciencedocs-cluster/pry-sciencedocs-svc	Task definition: revision: pry-sciencedocs-task:2
Created by: arn:aws:iam:207443664335:role/voclabs	Platform version: LATEST
Propagate tags from: None	Availability Zone rebalancing: Turned on
Launch type: Fargate	Platform family: Linux
CloudFormation stack: -	Scheduling strategy: REPLICA
Amazon ECS managed tags: Turned off	ECS Exec: Turned off

Network configuration	
VPC: vpc-09280ddcc2fca7113	Subnets: subnet-0d64430551519cb21, subnet-05cd557f3f0f6b210, subnet-089ab748cb6661b2f, subnet-0f281ea9c6d1792a1
Security groups: sg-05882e70aec661c74	Auto-assign public IP: Turned on
Service role: AWSServiceRoleForECS	Health check grace period: 0 seconds
DNS names: -	

4. Validacion End-to-End

Se ejecutaron ocho pruebas funcionales sobre la API en produccion, cubriendo los cinco endpoints y ambas familias de modelos. Todas pasaron sin errores.

#	PRUEBA	RESULTADO
1	GET /health	200 OK - gemini_key_set=true, ambos modelos cargados
2	GET /modelos	200 OK - 2 familias listadas en los 3 endpoints POST
3	POST /clasificar con scibeto ("Se reclutaron 100 pacientes...")	METH - confianza 96.81 %
4	POST /clasificar con gemini (mismo texto)	METH - confianza 95 %
5	POST /contribucion con scibeto ("Este trabajo propone...")	contribucion - confianza 99.98 %
6	POST /contribucion con gemini (mismo texto)	contribucion - confianza 95 %
7	POST /analizar con scibeto (3 parrafos)	n_fragmentos=3, T1+T2 OK, latencia ~1 s
8	POST /analizar con gemini (3 parrafos)	n_fragmentos=3, INTRO+CONTR+LIM perfectos, latencia ~10 s

4.1. Health check

```
$ curl http://100.27.211.193:8000/health
{
  "status": "ok",
  "t1_model": "wiflore/SciBETO-IMRaD",
  "t2_model": "wiflore/SciBETO-T2-contribucion",
  "gemini_key_set": true
}
```

4.2. Pipeline integrado /analizar

El endpoint /analizar segmenta el texto por linea en blanco (separador "\n\n") y aplica T1+T2 a cada parrafo. Devuelve la lista de fragmentos con etiqueta, confianza y probabilidades para cada tarea.

```
$ curl -X POST http://100.27.211.193:8000/analizar \
-H "Content-Type: application/json" \
-d '{"texto":"El objetivo es evaluar...\n\nEste trabajo propone...\n\nSin embargo, los resultados estan limitados.", "modelo":"scibeto"}'

{
  "n_fragmentos": 3,
```



```
"modelo": "scibeto",
"fragmentos": [
  {
    "fragmento": "El objetivo es evaluar...",
    "t1": "METH", "confianza_t1": 0.87,
    "t2": "no_contribucion", "confianza_t2": 0.75,
    "modelo_t1": "wiflore/SciBETO-IMRaD",
    "modelo_t2": "wiflore/SciBETO-T2-contribucion"
  },
  { "...": "fragmento 2 (contribucion 99.98%)" },
  { "...": "fragmento 3 (LIM 87% / no_contribucion 98%)" }
]
}
```